

# EST-46115: Modelación Bayesiana

**Profesor:** Alfredo Garbuno Iñigo — Primavera, 2021.

**Objetivo.** Repasar notación que utilizaremos a lo largo del curso. Y a la vez, establecer la motivación de los temas que trataremos en la materia.

**Lecturas recomendadas:** Notas del [curso de fundamentos](#) (2022) y sección 1 de [2].

## 1. NOTACIÓN

Usaremos la convención usual en probabilidad.

### 1.1. Variables aleatorias

Una variable aleatoria  $X$  está definida a través de un **espacio de probabilidad**  $(\mathcal{X}, \mathcal{F}, \pi)$ . La función  $\pi : \mathcal{F} \rightarrow [0, 1]$  se llama la **función de distribución** de la variable aleatoria  $X$ . Escribimos  $X \sim \pi$ .

### 1.2. Distribución paramétrica

Decimos que una función de distribución es **paramétrica** si se puede identificar completamente la distribución con respecto a un **vector de parámetros**  $\theta \in \mathbb{R}^p$ . Esto lo denotamos de la siguiente manera

$$\pi_{\theta}(x) \quad \text{ó} \quad \pi(x; \theta), \quad (1)$$

y si  $\theta \neq \theta'$  entonces  $\pi_{\theta}(x) \neq \pi_{\theta'}(x)$  para cualquier  $x$  en el **soporte**.

### 1.3. Valores esperados

El **valor esperado** de una variable aleatoria  $X \sim \pi$  se define como

$$\mathbb{E}[X] = \int_{\mathcal{X}} x \pi(x) dx. \quad (2)$$

*1.3.1. Abuso de notación* La **función de densidad** está definida como  $d\pi/dx$ . En la definición de valor esperado deberíamos de haber escrito  $d\pi(x)$  o bien  $\pi(dx)$  (integrales de Lebesgue). Pero para no ofuscar notación, y dado que no veremos cosas exóticas en el curso, lo obviaremos...

### 1.4. Estadísticas de interés

La definición se puede extender con  $f : \mathcal{X} \rightarrow \mathbb{R}$  y se calcula como

$$\mathbb{E}[f(X)] = \int_{\mathcal{X}} f(x) \pi(x) dx. \quad (3)$$

Denotaremos de la siguiente manera

$$\pi(f) := \mathbb{E}[f(X)]. \quad (4)$$




FIGURA 1. Tomado de [4] .

### 1.5. Probabilidad condicional

La probabilidad condicional de  $A$  dado el evento  $B$  se denota  $\pi(A|B)$  y está definida como

$$\pi(A|B) = \frac{\pi(A \cap B)}{\pi(B)} \quad (5)$$

## 2. REPASO INFERENCIA

Repaso de inferencia bajo un enfoque frecuentista.

### 2.1. Regla de Bayes

La regla de Bayes utiliza la definición de probabilidad condicional para hacer inferencia a través de

$$\pi(A|B) = \frac{\pi(B|A)\pi(A)}{\pi(B)}. \quad (6)$$

### 2.2. Ejemplos

- Verosimilitud:  $x|\theta \sim \text{Binomial}(n, \theta)$  + Previa:  $\theta \sim \text{Beta}(\alpha, \beta)$  = Posterior: ?
- Verosimilitud:  $x|\theta \sim \text{Uniforme}(0, \theta)$  + Previa:  $\theta \sim \text{Pareto}(\theta_0)$  = Posterior: ?

## 3. REPASO INFERENCIA

Repaso de inferencia bajo un enfoque bayesiano.

### 3.1. Ejemplo

Este ejemplo fue tomado de [3].

### 3.2. Diferentes previas, diferentes posteriores

```
1 modelo_beta <- function(params, n = 5000){
2   rbeta(n, params$alpha, params$beta)
3 }
```

```

1 escenarios <-
2   tibble(analista = fct_inorder(c("Ignorante", "Indiferente",
3                                 "Feminista", "Ingenuo")),
4         alpha = c(1, .5, 5, 14),
5         beta = c(1, .5, 11, 1)) |>
6   nest(params.previa = c(alpha, beta)) |>
7   mutate(muestras.previa = map(params.previa, modelo_beta))

```



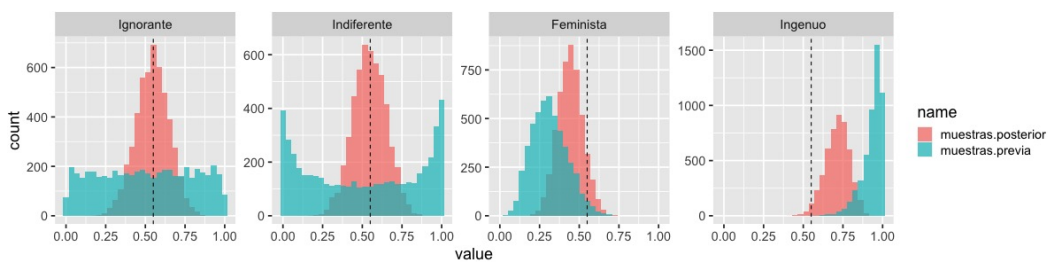
FIGURA 2. Muestras de  $\theta \sim$  Previa .

FIGURA 3. Distribución predictiva previa

```

1 update_rule <- function(params){
2   tibble(alpha = params$alpha + data$PASS,
3         beta = params$beta + data$FAIL)
4 }
5 escenarios <- escenarios |>
6   mutate(params.posterior = map(params.previa, update_rule),
7         muestras.posterior = map(params.posterior, modelo_beta))

```







FIGURA 4. Predictiva posterior.

### 3.3. Diferentes datos, diferentes posteriores



## 4. MOTIVACIÓN

Por medio de metodología Bayesiana podemos cuantificar incertidumbre en:

- Observaciones.
- Parámetros.
- Estructura.

Es fácil especificar y ajustar modelos. Pero hay preguntas cuyas respuestas no han quedado claras:

1. Construcción.
2. Evaluación.
3. Uso.

Programación probabilística.

Los aspectos del flujo de trabajo Bayesiano consideran ([2]):

1. Construcción iterativa de modelos.
2. Validación de modelo (computacional).
3. Entendimiento de modelo.
4. Evaluación de modelo.

#### 4.1. Distinción importante

Inferencia no es lo mismo que análisis de datos o que un flujo de trabajo.

Inferencia (en el contexto bayesiano) es formular y calcular con probabilidades condicionales.

#### 4.2. ¿Por qué necesitamos un flujo de trabajo?

- El cómputo puede ser complejo.

- Expandir nuestro entendimiento en aplicaciones.
- Entender la relación entre modelos.
- Distintos modelos pueden llegar a distintas conclusiones.

### 4.3. Proceso iterativo

- La gente de ML sabe que el proceso de construcción de un modelo es iterativo, ¿por qué no utilizarlo?

Una posible explicación puede encontrarse en [1]. El argumento es formal en cuanto a actualizar nuestras creencias como bayesianos. Sin embargo, con cuidado y un procedimiento científico puede resolver el asunto.

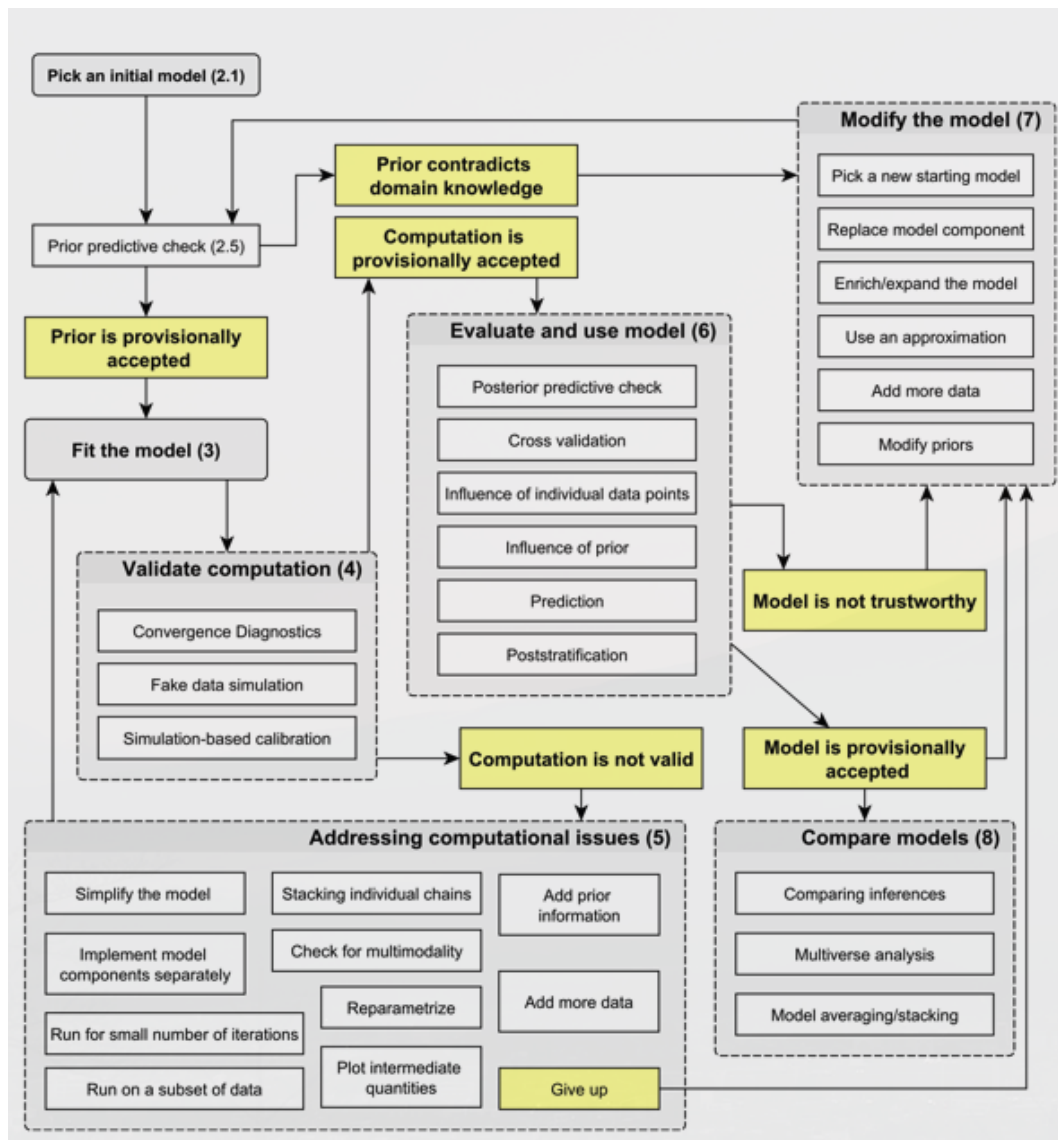


FIGURA 5. Tomado de [2].

## REFERENCIAS

- [1] A. Gelman and Y. Yao. Holes in Bayesian statistics. *Journal of Physics G: Nuclear and Particle Physics*, 48(1):014002, jan 2021. ISSN 0954-3899, 1361-6471. . [5](#)
- [2] A. Gelman, A. Vehtari, D. Simpson, C. C. Margossian, B. Carpenter, Y. Yao, L. Kennedy, J. Gabry, P.-C. Bürkner, and M. Modrák. Bayesian workflow. *arXiv preprint arXiv:2011.01808*, 2020. [1](#), [4](#), [5](#)
- [3] A. Johnson, M. Ott, and M. Dogucu. *Bayes Rules! An Introduction to Applied Bayesian Modeling*. 2021. [2](#)
- [4] J. Kruschke. *Doing Bayesian Data Analysis: A Tutorial with R, JAGS, and Stan*. Academic Press, 2014. [2](#)