

EST-46115: Modelación Bayesiana

Profesor: Alfredo Garbuno Iñigo — Primavera, 2022.

Objetivo. Estudiar integración en el contexto probabilístico. Estudiar el método Monte Carlo y entender sus bondades y limitaciones en el contexto de inferencia Bayesiana.

Lectura recomendada: Sección 6.1 de [1].

1. INTRODUCCIÓN

En inferencia bayesiana lo que queremos es poder resolver

$$\mathbb{E}[f] = \int_{\Theta} f(\theta) \pi(\theta|y) d\theta. \quad (1)$$

Lo que necesitamos es resolver integrales con respecto a la distribución de interés.

- La pregunta clave (I) es: ¿qué distribución?
- La pregunta clave (II) es: ¿con qué método numérico resuelvo la integral?
- La pregunta clave (III) es: ¿y si no hay método numérico?

2. INTEGRACIÓN NUMÉRICA

Recordemos la definición de integrales Riemann:

$$\int f(x) dx.$$

La aproximación utilizando una malla de N puntos sería:

$$\sum_{n=1}^N f(u_n) \Delta u_n.$$

El método útil cuando las integrales se realizan cuando tenemos pocos parámetros. Es decir, $\theta \in \mathbb{R}^p$ con p pequeña.

2.1. Ejemplo: Proporción

Supongamos que $p(S_n = k|\theta) \propto \theta^k(1 - \theta)^{n-k}$ cuando observamos k éxitos en n pruebas independientes. Supongamos que nuestra inicial es $p(\theta) = 2\theta$ (checha que es una densidad).

```
1 crear_log_post <- function(n, k){  
2   function(theta){  
3     verosim <- k * log(theta) + (n - k) * log(1 - theta)
```




FIGURA 1. Integral por medio de discretización.




FIGURA 2. Integral por medio de una malla fina.

```

4     inicial <- log(theta)
5     verosim + inicial
6   }
7 }

```

```

1 # observamos 3 exitos en 4 pruebas:
2 log_post <- crear_log_post(4, 3)
3 prob_post <- function(x) { exp(log_post(x)) }
4 # integramos num ricamente
5 p_x <- integrate(prob_post, lower = 0, upper = 1, subdivisions = 100L)
6 p_x

```

```

1 0.033 with absolute error < 3.7e-16

```

Y ahora podemos calcular la media posterior:

$$\mathbb{E}[\theta] = \int \theta \pi(\theta|S_n) d\theta. \quad (2)$$

```

1 media_funcion <- function(theta){
2   theta * prob_post(theta) / p_x$value
3 }
4 integral_media <- integrate(media_funcion,
5                               lower = 0, upper = 1,
6                               subdivisions = 100L)
7 media_post <- integral_media$value
8 c(Numerico = media_post, Analitico = 5/(2+5))

```

```

1 Numerico Analitico
2 0.71      0.71

```

2.2. Más de un parámetro

Consideramos ahora un espacio con $\theta \in \mathbb{R}^p$. Si conservamos N puntos por cada dimensión, ¿cuántos puntos en la malla necesitaríamos? Lo que tenemos son recursos computacionales limitados y hay que buscar hacer el mejor uso de ellos. En el ejemplo, hay zonas donde no habrá contribución en la integral.

3. INTEGRACIÓN MONTE CARLO

$$\pi(f) = \mathbb{E}_\pi[f] = \int f(x) \pi(x) dx,$$

$$\pi_N^{\text{MC}}(f) = \frac{1}{N} \sum_{n=1}^N f(x^{(n)}), \quad \text{donde } x^{(n)} \stackrel{\text{iid}}{\sim} \pi, \quad \text{con } n = 1, \dots, N,$$

$$\pi(f) \approx \pi_N^{\text{MC}}(f).$$

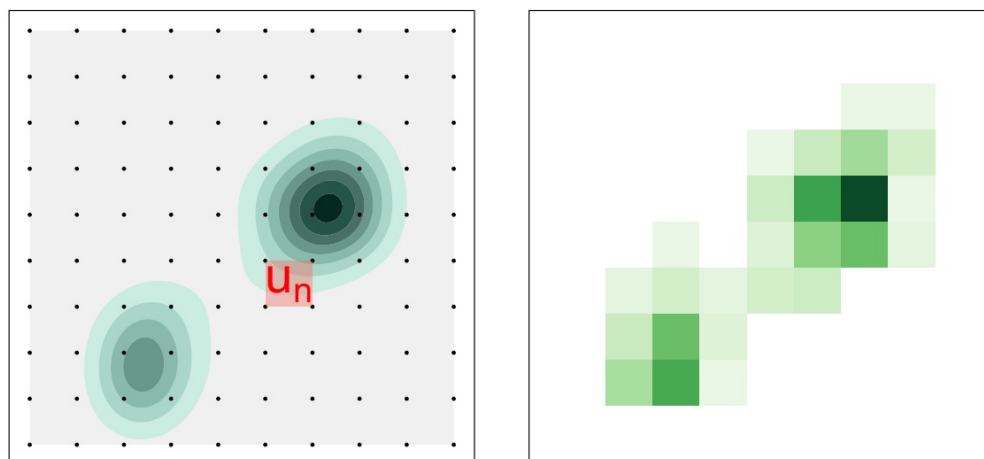


FIGURA 3. Integral por método de malla.




FIGURA 4. Integración Monte Carlo para aproximar π .




FIGURA 5. Estimación $\pi_N^{MC}(f)$ con $N \rightarrow \infty$.

3.1. Ejemplo: Dardos

Consideremos el experimento de lanzar dardos uniformemente en un cuadrado de tamaño 2, el cual contiene un círculo de radio 1.

3.2. Propiedades

Teorema (Error Monte Carlo). Sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ cualquier función bien comportada[†]. Entonces, el estimador Monte Carlo es **insesgado**. Es decir, se satisface

$$\mathbb{E} \left[\pi_N^{\text{MC}}(f) - \pi(f) \right] = 0,$$

para cualquier N . Además tiene **error cuadrático medio acotado**

$$\sup_{f \in \mathcal{F}} \mathbb{E} \left[\left(\pi_N^{\text{MC}}(f) - \pi(f) \right)^2 \right] \leq \frac{1}{N}.$$

En particular, la varianza del estimador (**error estándar**) satisface la igualdad

$$\text{ee}^2 \left(\pi_N^{\text{MC}}(f) \right) = \frac{\mathbb{V}_\pi(f)}{N}.$$

Teorema (TLC para estimadores Monte Carlo). Sea f una función bien comportada^{††}, entonces bajo una N suficientemente grande tenemos

$$\sqrt{N} \left(\pi_N^{\text{MC}}(f) - \pi(f) \right) \sim \mathbf{N}(0, \mathbb{V}_\pi(f)). \quad (3)$$

3.3. Ejemplo: Proporciones

Consideramos la estimación de una proporción θ , tenemos como inicial $p(\theta) \propto \theta$, que es una $\text{Beta}(2, 1)$. Si observamos 3 éxitos en 4 pruebas, entonces sabemos que la posterior es $p(\theta|x) \propto \theta^4(1-\theta)$, que es una $\text{Beta}(5, 2)$. Si queremos calcular la media y el segundo momento posterior para θ , en teoría necesitamos calcular

$$\mu_1 = \int_0^1 \theta p(\theta|X=3) d\theta, \quad \mu_2 = \int_0^1 \theta^2 p(\theta|X=3) d\theta. \quad (4)$$

Utilizando el método Monte Carlo:

```
1 theta <- rbeta(10000, 5, 2)
2 media_post <- mean(theta)
3 momento_2_post <- mean(theta^2)
4 c(mu_1 = media_post, mu_2 = momento_2_post)
```

```
1 mu_1 mu_2
2 0.72 0.54
```

Incluso, podemos calcular cosas mas *exóticas* como

$$P(e^\theta > 2|x). \quad (5)$$

```
1 mean(exp(theta) > 2)
```

```
1 [1] 0.61
```

3.4. Ejemplo: Sabores de helados

Supongamos que probamos el nivel de gusto para 4 sabores distintos de una paleta. Usamos 4 muestras de aproximadamente 50 personas diferentes para cada sabor, y cada uno evalúa si le gustó mucho o no. Obtenemos los siguientes resultados:

	sabor	n	gusto	prop_gust
1	fresa	50	36	0.72
2	limon	45	35	0.78
3	mango	51	42	0.82
4	guanabana	50	29	0.58

LISTING 1. Resultados de las encuestas.

Usaremos como inicial $\text{Beta}(2, 1)$ (pues hemos observado cierto sesgo de cortesía en la calificación de sabores, y no es tan probable tener valores muy bajos) para todos los sabores, es decir $p(\theta_i)$ es la función de densidad de una $\text{Beta}(2, 1)$. La inicial conjunta la definimos entonces, usando `independencia_inicial`, como

$$p(\theta_1, \theta_2, \theta_3, \theta_4) = p(\theta_1)p(\theta_2)p(\theta_3)p(\theta_4).$$

Pues inicialmente establecemos que ningún parámetro da información sobre otro: saber que mango es muy gustado no nos dice nada acerca del gusto por fresa. Bajo este supuesto, y el supuesto adicional de que las muestras de cada sabor son independientes, podemos mostrar que las posteriores son independientes:

$$p(\theta_1, \theta_2, \theta_3, \theta_4 | k_1, k_2, k_3, k_4) = p(\theta_1 | k_1)p(\theta_2 | k_2)p(\theta_3 | k_3)p(\theta_4 | k_4)$$

	sabor	n	gusto	prop_gust	a_post	b_post	media_post
1	fresa	50	36	0.72	38	15	0.72
2	limon	45	35	0.78	37	11	0.77
3	mango	51	42	0.82	44	10	0.81
4	guanabana	50	29	0.58	31	22	0.58

LISTING 2. Resultado de inferencia Bayesiana.

Podemos hacer preguntas interesantes como: ¿cuál es la probabilidad de que mango sea el sabor preferido? Para contestar esta pregunta podemos utilizar simulación y responder por medio de un procedimiento Monte Carlo.

```

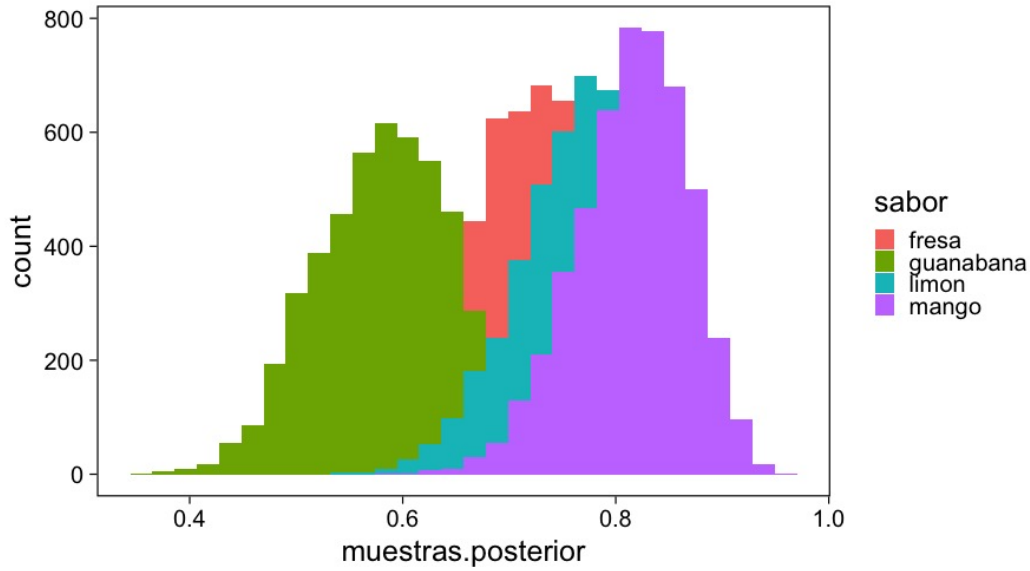
1 ## Generamos muestras de la posterior
2 paletas <- datos |>
3   mutate(alpha = a_post, beta = b_post) |>
4   nest(params.posterior = c(alpha, beta)) |>
5   mutate(muestras.posterior = map(params.posterior, modelo_beta)) |>
6   select(sabor, muestras.posterior)

```

```

1 ## Utilizamos el metodo Monte Carlo para aproximar la integral.
2 paletas |>
3   unnest(muestras.posterior) |>
4   mutate(id = rep(seq(1, 5000), 4)) |> group_by(id) |>
5   summarise(favorito = sabor[which.max(muestras.posterior)]) |>
6   group_by(favorito) |> tally() |>
7   mutate(prop = n/sum(n)) |>
8   as.data.frame()

```

FIGURA 6. Histogramas de la distribución predictiva marginal para cada θ_j .

	favorito	n	prop
1	fresa	321	0.0642
2	guanabana	2	0.0004
3	limon	1327	0.2654
4	mango	3350	0.6700

LISTING 3. Aproximación Monte Carlo.

Escencialmente estamos preguntándonos sobre calcular la integral:

$$\mathbb{P}(\text{mango sea preferido}) = \int_{\Theta} f(\theta_1, \dots, \theta_4) p(\theta_1, \dots, \theta_4 | X_1, \dots, X_n) d\theta, \quad (6)$$

donde $f(\theta_1, \dots, \theta_4) = \mathbb{I}_{[\theta_4 \geq \theta_j, j \neq 4]}(\theta_1, \dots, \theta_4)$.

3.5. Tarea: Sabores de helados

- ¿Cuál es la probabilidad a priori de que cada sabor sea el preferido?
- Con los datos de arriba, calcula la probabilidad de que la gente prefiera el sabor de mango sobre limón.

REFERENCIAS

- [1] A. Johnson, M. Ott, and M. Dogucu. *Bayes Rules! An Introduction to Applied Bayesian Modeling*. 2021. [1](#)